

实验四：语音合成

——以 MeloTTS 为例

助教：陈俊洋

指导老师：秦勇教授

研究方向：语音编辑、语音合成、语音大模型



一、VITS 的架构和基本原理


二、语音合成实验

- 作业 1: MeloTTS 安装与 API 使用
- 作业 2: 多音字语音合成
- 作业 3: 韵律控制实验
- 作业 4: 训练与推理优化

▶ VITS 的架构和基本原理

研究背景：两阶段 TTS 的瓶颈

传统 TTS 通常被拆成两个生成阶段：



主要问题

- 训练割裂：后端声码器常需要用前端预测结果再微调
- 中间特征固定：mel 频谱是人为设定的瓶颈表示
- 端到端模型此前虽可并行，但音质仍落后于两阶段强系统

VITS 的目标

端到端训练
Single-stage

并行采样
Parallel


直接生成波形
Text → Waveform

核心想法：用潜变量 z 把文本侧先验和语音侧后验连接起来，并用 **GAN** 的对抗训练提升生成音频的质量。


Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech

▶ VITS 的架构和基本原理


VITS 的训练阶段:



变分自编码器 (Variational Auto-Encoders, VAE)




CVAE



约束条件: ELBO:
$$\tilde{\mathcal{L}}_{\text{VAE}}(\mathbf{x}; \theta, \phi) = -KL(q_\phi(\mathbf{z}|\mathbf{x})||p_\theta(\mathbf{z})) + \frac{1}{L} \sum_{l=1}^L \log p_\theta(\mathbf{x}|\mathbf{z}^{(l)})$$

- 1、输入样本 x_i 和输出样本 $g_\theta(\mathbf{z})$ 尽可能相似
- 2、后验分布 $q_\phi(\mathbf{z}|\mathbf{x})$ 尽可能接近先验分布 $p_\theta(\mathbf{z})$ ，即标准正态分布

▶ 文本分布映射与 Flow



这里的先验分布 $p_\theta(z | c)$ 不再是 VAE 中的标准正态分布，而是由文本控制

文本：


G2P -> Text Encoder -> Projection -> 文本先验分布的两个参数 μ_θ 和 σ_θ

需要解决的问题：

- 1、语音后验分布和文本先验分布不匹配
- 2、语音隐变量和文本隐变量的长度不匹配

针对问题1，作者使用了 normalizing flow 模型，可以将一个分布 **可逆** 地映射为另一个分布


► Monotonic Alignment Search (MAS)



需要解决的问题:

2、语音隐变量和文本隐变量的长度不匹配

Monotonic Alignment Search 单调对齐搜索



单调性、连续性


► Monotonic Alignment Search (MAS)

MAS 对齐矩阵 Q_{ij} , 通过计算 z_j 在 $N(\mu_{hi}, \sigma_{hi})$ 中的概率得到

Q_{ij}	z1	z2	z3	z4	z5	z6	z7	z8
我	0.9	0.1	0.1	0.1	0.1	0.1	0.1	0.1
是	0.1	0.9	0.1	0.1	0.1	0.1	0.1	0.1
中	0.1	0.1	0.8	0.9	0.1	0.1	0.1	0.1
国	0.1	0.1	0.1	0.1	0.9	0.9	0.1	0.1
人	0.1	0.1	0.1	0.1	0.1	0.1	0.8	0.9



最大似然矩阵 A^* : $Q_{i,j} = \max(Q_{i-1,j-1}, Q_{i,j-1}) + \log N(z_j; \mu_i, \sigma_i)$

Q_{ij}	z1	z2	z3	z4	z5	z6	z7	z8
我	0.9	1.0	0.2	0.2	0.2	0.2	0.2	0.2
是	0.1	1.8	1.0	0.2	0.2	0.2	0.2	0.2
中	0.1	0.2	2.6	3.5	1.0	0.2	0.2	0.2
国	0.1	0.2	0.2	0.9	4.4	5.3	1.0	0.2
人	0.1	0.2	0.2	0.2	0.2	1.0	6.1	7.0



纯算法实现, 没有神经网络, 不需要训练

▶ SDP & Loss



CVAE {

$$L_{recon} = \|x_{mel} - \hat{x}_{mel}\|_1 \rightarrow \text{统一成 mel}$$

$$L_{kl} = \log q_\phi(z|x_{lin}) - \log p_\theta(z|c_{text}, A)$$

GAN {


$$L_{adv}(D) = \mathbb{E}_{(y,z)} [(D(y) - 1)^2 + (D(G(z)))^2],$$

$$L_{adv}(G) = \mathbb{E}_z [(D(G(z)) - 1)^2],$$


$$L_{fm}(G) = \mathbb{E}_{(y,z)} \left[\sum_{l=1}^T \frac{1}{N_l} \|D^l(y) - D^l(G(z))\|_1 \right]$$

$$L_{vae} = \underline{L_{recon}} + \underline{L_{kl}} + \underline{L_{dur}} + \underline{L_{adv}(G)} + \underline{L_{fm}(G)}$$

► Inference procedure



(a) Training procedure



(b) Inference procedure

一句话总结

VITS = 用 CVAE 解决端到端训练，用 Flow/MAS/SDP 解决分布、对齐和韵律，用 GAN 解决生成波形质量。

第二部分：语音合成实验

- 作业 1：MeloTTS 安装与 API 使用
- 作业 2：多音字语音合成
- 作业 3：韵律控制实验
- 作业 4：训练与推理优化

▷ 实验说明

实验简介

实验内容围绕开源多语言文本转语音系统 MeloTTS 展开，旨在帮助学生从原理分析与工程实践两个层面理解现代 TTS (Text-to-Speech) 系统的基本流程。

实验内容概览

包含四次实验，前 3 次为必做实验(90%)，第 4 次为拓展实验（作为加分项，10%）。

实验编号	实验代码	实验主题	核心内容
Homework 1	tts_homework_1.ipynb	MeloTTS 安装与 API 使用	环境配置、模型加载、基础语音合成、参数理解
Homework 2	tts_homework_2.ipynb	多音字语音合成	文本前端、TN/G2P、多音字定制控制
Homework 3	tts_homework_3.ipynb	韵律控制实验	VITS 结构、MAS/SDP、时长调整与韵律变化
Homework 4	tts_homework_4.ipynb	训练与推理优化	自定义音色训练 或 ONNX 推理优化

▶ 实验说明

下载与环境配置

下载地址: <https://github.com/CJY1018/MeloTTS-Homework>

或Gitee: (<https://gitee.com/cjy1018/MeloTTS-Homework>)

环境安装与用例: <https://github.com/CJY1018/MeloTTS-Homework/blob/main/install.md>

unidic 字典需要科学上网环境下载: `python -m unidic download`

使用 modelscope 下载:

`modelscope download --model CJY1018/dicdir --local_dir ./dicdir`

本次实验尽可能使用国内网络环境进行资源下载和模型训练, 如果遇到网络问题导致无法下载资源或依赖环境, 请参考以下解决方案:

1. 使用国内镜像源 (如清华大学、阿里云等) 替换默认的 PyPI 镜像源, 安装依赖时加上 `-i https://pypi.tuna.tsinghua.edu.cn/simple` 参数。
2. 使用 [HF-Mirror](#) 等国内镜像站点下载 Hugging Face 上的模型和数据集。
3. 使用 [ModelScope](#) 等国内平台提供的预训练模型和数据集。
4. 搜索 MeloTTS 的安装教程和解决方案, 参考国内社区 (如 CSDN、知乎等) 上的相关讨论和经验分享。
5. 如果仍然无法解决网络问题, 请尝试使用科学上网工具访问相关资源。

▶ 实验说明

实验提交要求

完成 Jupyter Notebook 内的实验内容，将答案和相关代码填写在 “姓名-学号-TTS实验报告模板.docx” 中（也可自行改为 latex 模板），并和生成的音频文件一起打包提交。

参考资料：

Vits 论文：<https://arxiv.org/abs/2106.06103>

MeloTTS 官方仓库：<https://github.com/myshell-ai/MeloTTS>

Vits 原理讲解视频：<https://www.bilibili.com/video/BV1Jb4y1g7q6>

MeloTTS 训练教程博客：<https://blog.lukeewin.top/archives/melotts-zh-model-train>

MeloTTS 转 ONNX 部署优化工具：<https://github.com/k2-fsa/sherpa-onnx>



THANKS!
Q&A