

目录

实验一：环境安装与 ECAPA-TDNN 初次推理 (15%)	2
【问题一】 waveform 读取与数值范围	2
【问题二】 SpeechBrain checkpoint 结构	2
【问题三】 embedding 每个维度是否有明确语义?	3
实验二：说话人嵌入空间与扰动分析 (35%)	4
【问题一】 为什么需要对两种 embeddings 联合拟合 t-SNE?	4
【问题二】 性别和个体的聚类现象	4
【问题三】 扰动是否可能改变说话人身份?	4
【问题四】 数据集 domain mismatch	5
实验三：说话人验证与说话人辨认 (50%)	6
【问题一】 Speaker Templates	6
【问题二】 Dev EER	6
【问题三】 Identification 和 verification 的区别	6
【问题四】 为什么说话人验证常用 cosine similarity?	6
【问题五】 阈值选择与错误代价	7
【问题六】 为什么不能在 test trials 上调 threshold?	7
【问题七】 为什么模型能在未见过的 AISHELL speaker 上做 verification/identification 任务?	7

实验一：环境安装与 ECAPA-TDNN 初次推理（15%）

【问题一】 waveform 读取与数值范围

查阅 [Torchaudio Doc](<https://docs.pytorch.org/audio/stable/index.html>), 结合本实验输出, 回答:

- `torchaudio.load()` 默认返回的 `signal dtype` 是什么?
- 默认返回的 `signal shape` 是什么? `[channel, time]` 还是 `[time, channel]`?
- 使用 SciPy 包的 ``scipy.io.wavfile.read()`` 方法也可以读取音频。对于 16-bit PCM WAV, `torchaudio.load()` 和 `scipy.io.wavfile.read()` 得到的数据 `dtype` 和数值范围分别是什么?
- 如果把 `scipy.io.wavfile.read()` 得到的 `int16` 数据不缩放, 直接转成 Tensor 输入 `encode_batch()`, 你预期会出现什么问题? 请用一小段实验验证你的判断。

答:

【问题二】 SpeechBrain checkpoint 结构

查阅 [Speechbrain Doc](<https://speechbrain.readthedocs.io/en/latest>) 和本地 `ckpt/spkrec-ecapa-cnceleb/hyperparams.yaml`, 回答:

- 本 checkpoint 中 `modules` 包含哪些模块?
- `compute_features`、`mean_var_norm`、`embedding_model`、`classifier` 分别有什么用途?
- `lin_neurons=192` 表示什么?
- `out_n_neurons=2793` 表示什么?
- `encode_batch()` 是否会使用 `classifier`? 如果不会, `classifier` 在训练和 `classify_batch()` 中的作用是什么?

答:

【问题三】 embedding 每个维度是否有明确语义？

`embeddings` 的 shape 是 [1, 1, 192] 或 [192]。请解释：

- 这 192 个 dimension 是否分别代表“性别”“音高”“口音”“年龄”等人工可解释属性？
- 如果不是，为什么我们仍然可以用这个向量做说话人比对？
- 如果某些维度和性别、口音高度相关，这对系统公平性和隐私有什么潜在影响？

答：

实验二：说话人嵌入空间与扰动分析（35%）

【问题一】为什么需要对两种 embeddings 联合拟合 t-SNE？

本实验同时可视化 clean embeddings 和 perturbed/noisy embeddings。

- 如果分别对 clean embeddings 和 noisy embeddings 各自运行一次 t-SNE, 然后直接比较两张图中点的位置，这种比较是否严谨？为什么？

答：

【问题二】性别和个体的聚类现象

本实验中，t-SNE 图使用 marker shape 表示 gender, 使用 color 表示 speaker id。

请结合可视化结果回答：

- 如果观察到男声和女声在 t-SNE 空间中形成相对分离的两个大簇，这说明 speaker embedding 中可能包含哪些信息？
- 这种性别相关的聚类现象对说话人识别系统可能产生哪些影响？请分别从以下角度讨论：
 - 识别准确率：性别信息是否可能帮助模型区分说话人？它是否也可能使模型过度依赖非目标属性？
 - 算法公平性：不同性别群体的识别性能是否可能存在差异？这种差异可能带来什么问题？
 - 隐私保护：如果 speaker embedding 中包含性别等敏感属性信息，可能带来哪些隐私风险？

答：

【问题三】扰动是否可能改变说话人身份？

请尝试自己实现一种音频扰动方式。可以从可选扰动中选择一种，也可以自行设

计一种新的扰动方法。

完成后，请比较扰动前后模型提取到的 `speaker embeddings`，并分析：

- 这种扰动是否主要保持了说话人身份？
- 它是否明显改变了 `embedding` 的位置？
- 为什么这种扰动会带来当前观察到的影响量级？

（提交自行编写的代码和你认为必要的图表，并针对问题简要描述）

答：

【问题四】数据集 `domain mismatch`

本实验使用的模型训练于 `CN-Celeb`，但推理数据来自 `AISHELL`。请查阅 `CN-Celeb` 和 `AISHELL` 的录音场景或语料特点，并讨论：

- 二者都是中文语音，是否意味着不存在 `domain mismatch`？为什么？
- `AISHELL` 主要是较安静的朗读语音，这是否可能使本实验结果偏乐观？
- 如果将测试语音换成手机近场、会议远场或噪声环境下的语音，`speaker embedding` 的分布可能发生怎样的变化？可以基于你的观察和思考进行主观推测。

答：

实验三：说话人验证与说话人辨认（50%）

【问题一】 Speaker Templates

- 如果每个 speaker 只有一条 enrollment, template 是否仍然成立？

答：

【问题二】 Dev EER

答：

【问题三】 Identification 和 verification 的区别

请用自己的话说明：

- Speaker identification 关注的是什么问题？
- Speaker verification 关注的是什么问题？
- 为什么二者都可以使用 speaker embedding，但评测协议不同？

答：

【问题四】 为什么说话人验证常用 cosine similarity？

说话人验证为什么常用 cosine similarity 比较两个 embeddings？请从以下角度回答：

- embedding 是固定维度向量；
- L2 normalization 后 dot product 与 cosine similarity 的关系；

- 模型训练中常用 `angular / margin-based` 分类目标；（见补充阅读）
- `cosine score` 是否等价于概率？

答：

【问题五】 阈值选择与错误代价

假设一个系统用于门禁，另一个系统用于课堂签到：

- 哪个系统更不能接受 `false accept`？
- 哪个系统更不能接受 `false reject`？
- 这两个系统是否应该使用同一个 `threshold`？

答：

【问题六】 为什么不能在 `test trials` 上调 `threshold`？

- 请解释 `dev set` 和 `test set` 的区别。
- 如果你先在 `test trials` 上扫描 `threshold`，再报告该 `threshold` 下的 `test performance`，这样做有什么问题？

答：

【问题七】 为什么模型能在未见过的 AISHELL speaker 上做 `verification/identification` 任务？

CN-Celeb checkpoint 的训练目标本质上是对训练说话人做分类，
'out_n_neurons=2793'。但实验中我们拿它的 embedding 去验证/辨认 AISHELL
中未见过的说话人。请解释：

- 为什么分类训练得到的中间 embedding 可以迁移到未见过的 speaker?
- classifier head 和 embedding_model 在用途上有什么区别?
- 如果只使用 classifier 的输出类别，能否识别 AISHELL speaker?

答：