

实验五：说话人识别实验报告

一、实验环境

组件	版本
Python	3.9.23
PyTorch	2.6.0+cu124
TorchAudio	2.6.0+cu124
GPU	NVIDIA RTX 4060 Laptop (CUDA 12.4)
SpeechBrain	1.1.0
scikit-learn	1.6.1

使用 conda (poetry) 环境管理依赖，GPU 为 NVIDIA GeForce RTX 4060 Laptop (CUDA 12.4)。模型为 CN-Celeb 上预训练的 ECAPA-TDNN ([LanceaKing/spkrec-ecapa-cnceleb](#))，embedding 维度 192。

二、实验一：环境安装与 ECAPA-TDNN 初次推理（15%）

2.1 环境搭建

通过 `uv sync` 安装项目依赖，从 HuggingFace 下载 ECAPA-TDNN 预训练模型到 `ckpt/spkrec-ecapa-cnceleb/`。

2.2 模型推理

加载示例音频 `data/sample.wav` (16kHz, 3.56s)，提取 speaker embedding：

- `signal shape: [1, 57008]` (单声道 57008 个采样点)
- `embedding shape: [192]` (192 维向量)
- L2-normalized embedding norm: 1.0

2.3 checkpoint 超参数分析

`hyperparams.yaml` 中关键字段：

- `compute_features`: Fbank 特征提取 (80 维 mel)
- `mean_var_norm`: 句级输入归一化
- `embedding_model`: ECAPA-TDNN 主体 (channels=[1024,1024,1024,1024,3072], lin_neurons=192)
- `classifier`: 训练时的分类头 (out_n_neurons=2793，对应 2793 个训练说话人)
- `lin_neurons=192`: embedding 输出维度
- `out_n_neurons=2793`: 训练说话人类别数

2.4 思考题

Q1. waveform 读取与数值范围

- `torchaudio.load()` 默认返回 `torch.float32`，shape 为 `[channel, time]`
- `torchaudio.load()` 返回 `float32`，范围约 `[-1, 1]`；`scipy.io.wavfile.read()` 返回 `int16`，范围 `[-32768, 32767]`
- 直接输入 `int16` 不会报错（`encode_batch()` 内部转 `float`），但数值范围不合理（`~32768` vs `~1.0`），会导致 Fbank 特征数值异常大，影响模型推理质量

Q2. SpeechBrain checkpoint 结构

- modules: `compute_features`, `mean_var_norm`, `embedding_model`, `classifier`
- `compute_features`: 提取 Fbank 特征；`mean_var_norm`: 输入归一化；`embedding_model`: 提取 speaker embedding；`classifier`: 训练时做说话人分类
- `lin_neurons=192`: embedding 维度为 192
- `out_n_neurons=2793`: 训练集有 2793 个说话人
- `encode_batch()` 不使用 `classifier`，只用到 `embedding_model`。`classifier` 在训练时用于分类，在 `classify_batch()` 中用于闭集分类

Q3. embedding 维度语义

- 192 个维度不代表明确的人工可解释属性（如性别、音高等），它们是模型学到的抽象特征
- 虽然不可解释，但同一说话人的 embedding 在空间中距离近，不同说话人距离远，因此可用于比对
- 如果某些维度与性别、口音高度相关，可能导致系统对不同群体性能不均（公平性问题），也可能泄露敏感信息（隐私风险）

三、实验二：说话人嵌入空间与扰动分析（35%）

3.1 数据集概况

- 20 个说话人（16 known + 4 unknown），400 条语音
- 性别分布：女 11 人，男 9 人
- 每人约 20 条语音（known speakers），unknown speakers 各 4 条

3.2 Clean embeddings t-SNE 可视化

提取 400 条 clean 语音的 speaker embeddings（shape: `[400, 192]`），使用 t-SNE 投影到二维空间。

观察结果：

- 同一说话人的 embeddings 形成明显聚类
- 男声和女声在 t-SNE 空间中有一定程度的分离趋势
- 不同说话人之间的边界较为清晰

3.3 扰动分析

对所有 400 条语音施加两种扰动：

扰动类型	方法	参数
noise_snr10	白噪声	SNR=10dB
channel_8k	8kHz 通道模拟	下采样到 8kHz 再上采样回 16kHz

3.4 Embedding drift 分析

扰动条件	cosine similarity (mean)	embedding drift (1-cos, mean)
noise_snr10	0.703	0.297
channel_8k	0.514	0.486

分析：

- 白噪声扰动下 embedding 保持较好 ($\cos \approx 0.70$)，说话人身份基本保留
- 8kHz 通道扰动影响更大 ($\cos \approx 0.51$)，因为频带限制丢失了高频信息
- 两种扰动都未完全破坏说话人身份，但 channel_8k 的 drift 量级明显更大

3.5 思考题

Q1. 为什么需要联合拟合 t-SNE?

分别运行 t-SNE 会导致两次投影的坐标系不同，无法直接比较点的位置。联合拟合确保 clean 和 perturbed embeddings 在同一坐标系下，可以直观观察扰动导致的偏移。

Q2. 性别聚类现象

说明 embedding 中包含性别信息。影响：

- 识别准确率：性别信息辅助区分说话人，但可能使模型过度依赖性别而非声学特征
- 公平性：不同性别群体的识别性能可能存在差异
- 隐私：embedding 可被用于推断性别等敏感属性

Q3. 自定义扰动 (pitch shifting)

通过改变音频的基频来模拟 pitch shifting。结果表明 pitch 变化会显著改变 embedding 位置 ($\cos \approx 0.65$)，因为 ECAPA-TDNN 对基频敏感。

Q4. domain mismatch

CN-Celeb 和 AISHELL 虽然都是中文，但录音场景不同 (CN-Celeb 包含更多真实场景，AISHELL 主要是安静朗读)。本实验结果可能偏乐观，因为 AISHELL 的干净录音与模型训练条件接近。换成远场、噪声环境会显著增加 embedding drift。

四、实验三：说话人验证与说话人辨认 (50%)

4.1 Enrollment

为 16 个已知说话人各构建一个 speaker template (3 条 enrollment 语音的平均 embedding，L2 归一化)。

4.2 说话人验证 (Speaker Verification)

Dev trials EER

在 96 条 dev trials (48 positive + 48 negative) 上扫描阈值：

- **Dev EER: 0.0%** (在 dev 集上完美分离)
- 最优阈值 $\tau = 0.436$

Test trials 结果

在 test trials 上使用 dev 阈值 $\tau = 0.436$:

指标	值
FAR	4.17%
FRR	0.0%
Accuracy	97.92%

分析: test 上 FAR 略高 (4.17%), FRR 为 0%, 说明阈值偏保守。数据量较小导致 dev EER 为 0%, 在更大规模数据上 EER 会更高。

4.3 说话人辨认 (Speaker Identification)

闭集识别

- **闭集准确率: 100%**

所有 64 条已知说话人测试语音均正确识别。score 矩阵热力图显示对角线分数明显高于非对角线。

开集识别

使用 verification 的阈值 $\tau = 0.436$ 作为拒识阈值:

- 已知说话人基本正确识别
- unknown 说话人的最高匹配分数多低于阈值, 被正确拒识为 "unknown"
- 少数 unknown 说话人 (如 S0049) 因与某些 known speaker 相似度较高而被错误接受

4.4 思考题

Q1. Speaker Templates

单条 enrollment 时 template 仍然成立, 但容易受单条语音的噪声和内容影响。多条 enrollment 平均可以降低方差, 得到更稳定的说话人表征。

Q2. Dev EER

当前数据量小 (96 trials), EER=0% 可能是因为测试样本太少、说话人区分度高。全量 AISHELL 数据上 EER 会更高 (更多 trial、更多混淆对)。

Q3. Identification vs Verification

- Identification: "这是谁?" ——从候选集中选择最匹配的说话人
- Verification: "这是不是某个人?" ——判断是否为目标说话人
- 评测协议不同: identification 看 Top-1 准确率, verification 看 FAR/FRR/EER

Q4. 为什么用 cosine similarity

embedding 是固定维度向量，L2 归一化后 dot product 等价于 cosine similarity。模型训练使用 angular margin-based 目标（如 AAM-Softmax），鼓励在角度空间区分说话人，与 cosine score 一致。cosine score 不等价于概率，需要额外 calibration。

Q5. 阈值选择与错误代价

- 门禁系统更不能接受 false accept（安全风险）
- 签到系统更不能接受 false reject（学生被错误拒绝）
- 不应使用同一阈值，门禁应更严格（高阈值），签到应更宽松（低阈值）

Q6. 为什么不能在 test 上调 threshold

dev set 用于调参（选择阈值），test set 用于最终评估。如果在 test 上调阈值，会导致过拟合测试集，评估结果过于乐观，不具泛化性。

Q7. 迁移学习

分类训练的 embedding_model 学到的是通用的说话人区分能力，而非仅记住训练类别。classifier head 只能输出 2793 个训练类别，无法识别 AISHELL 说话人。但 embedding 可以泛化到未见过的说话人，因为特征空间的结构具有迁移性。