

实验五：说话人识别

助教：张砚喆

指导老师：秦勇教授

研究方向：语音鉴伪、说话人识别、语音大模型



○、为什么研究说话人？

一、说话人识别的任务族

二、说话人识别的发展历程


三、深度学习阶段的说话人识别模型：ECAPA-TDNN

四、实验

- 实验 1：环境安装与 ECAPA-TDNN 初次推理
- 实验 2：说话人嵌入空间与扰动分析
- 实验 3：说话人验证与说话人辨认

▷ 为什么研究说话人？

- 语音中不仅包含“说了什么”，也包含“谁在说”。




- **ASR**：语音内容识别
- **Speaker Recognition**：说话人身份识别
- **Speech Synthesis**：语音生成

▷ 说话人识别的任务族

Speaker Recognition

- Speaker Verification (说话人验证)：是不是某个人？
- Speaker Identification (说话人辨认)：是谁？
- Speaker Diarization (说话人日志)：什么时候谁在说？

说话人验证




注：图中 $\mathbb{R}^d$ 表示嵌入向量的 d 维实数空间，ECAPA-TDNN 输出的嵌入维度通常为 192 或 256 维。

说话人辨认

说话人辨认 Speaker Identification

核心问题：给定一段测试语音，从候选说话人集合中判断它是谁。



与说话人验证 (Speaker Verification) 的对比

项目	说话人验证 Speaker Verification	说话人辨认 Speaker Identification	
		闭集辨认 (Closed-set)	开集辨认 (Open-set)
核心问题	是不是某个人?	是谁?	是谁? 还是未知人?
输入	一个注册说话人 + 一段测试语音	候选说话人集合 + 一段测试语音	候选说话人集合 + 一段测试语音
输出	accept / reject	说话人 ID (一定来自候选集合)	说话人 ID 或 unknown
决策方式	与模板计算相似度, 与阈值比较	与所有模板计算相似度, 取最大者	最大相似度与阈值比较
关键超参数	阈值 τ	无显式阈值 (只做 argmax)	阈值 τ
常用指标	FAR, FRR, EER, Accuracy	Top-1 Accuracy, Top-k Accuracy	Closed-set Accuracy, Open-set Detection Rate, FPR@FAR

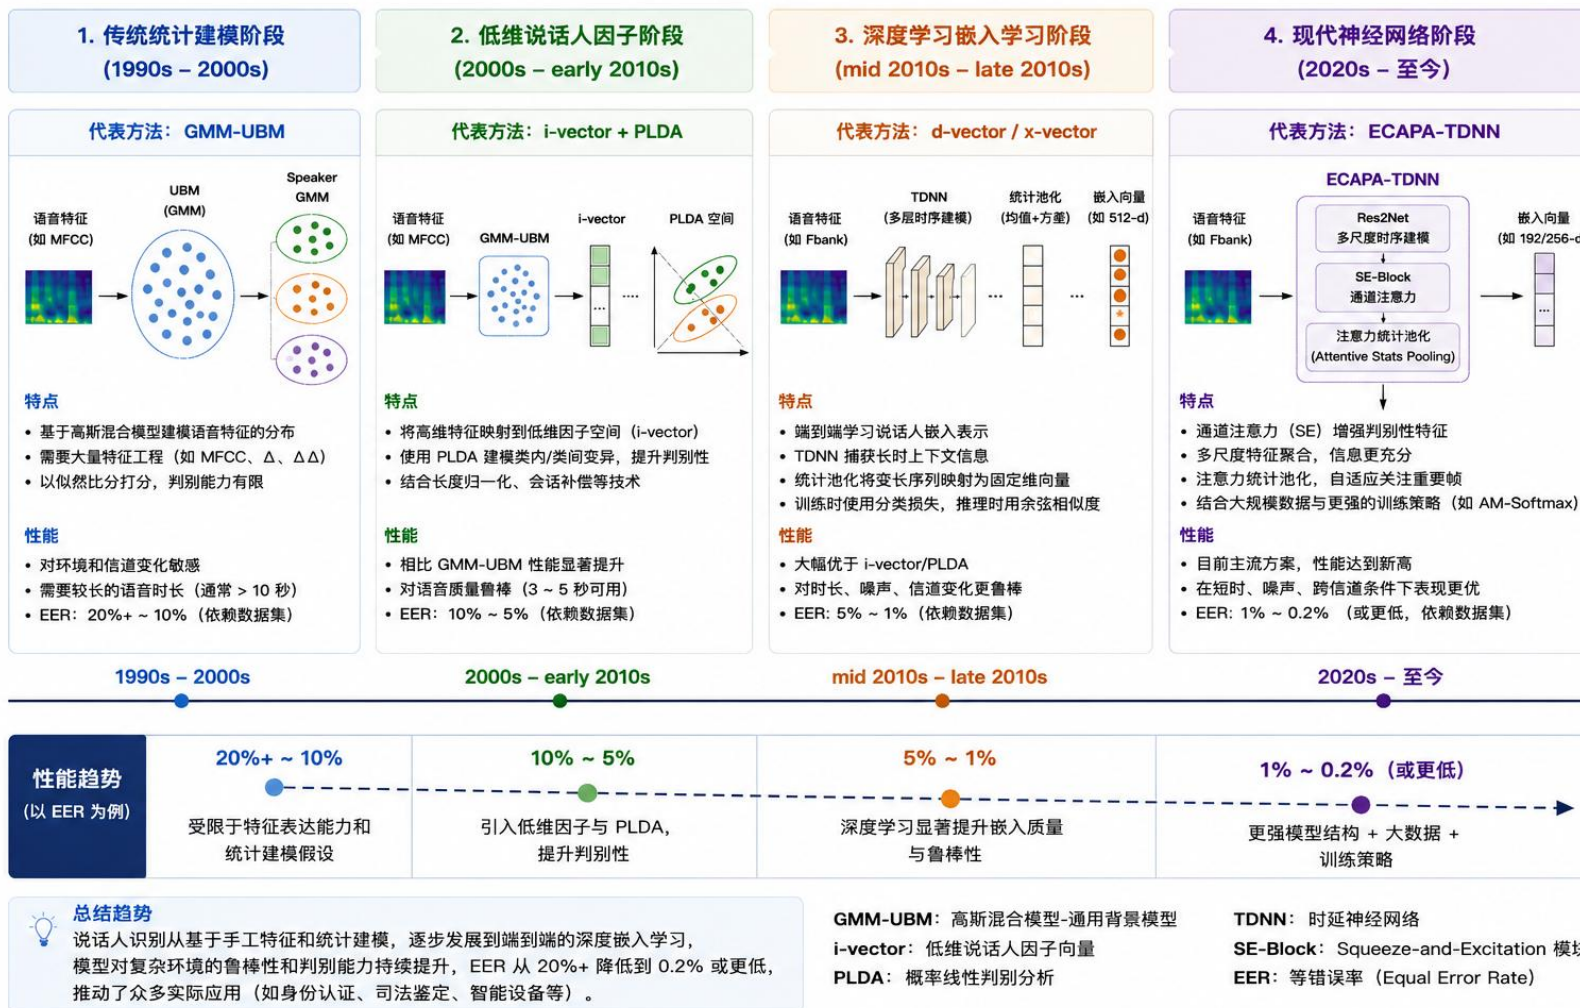
符号说明

x : 测试语音
 z_x : 测试语音的嵌入向量
 e_k : 第 k 位说话人的模板向量
 $score(s, x)$: 测试语音 x 与说话人 s 的相似度 (通常为余弦相似度)
 τ : 决策阈值 (仅验证与开集辨认使用)
 S : 候选说话人集合
 M : 候选说话人数量

小结: Verification 关注“是不是这个人”; Identification 关注“从一群人中选出是谁 (闭集)”或“判断是否是未知人 (开集)”。两者都依赖说话人嵌入与相似度计算, 但输入形式、决策方式和评估指标不同。

说话人识别的发展历程


说话人识别发展历程：从传统统计建模到深度学习时代



► 基于embedding的说话人识别


Embedding-based Speaker Recognition 的核心思想

好的 speaker embedding 应该让同一说话人的语音更近，不同说话人的语音更远。



- 同一 speaker 的点聚在一起 (类内紧凑)
- ← --- → 不同 speaker 的点分开 (类间分离)

现代 Neural Speaker Embedding Pipeline



训练阶段

使用大量带标签的说话人数据训练，通过分类损失 (如 Softmax / AAM-Softmax) 让模型区分训练集中的说话人。


推理阶段

丢弃或弱化分类头，使用中间的 speaker embedding 进行相似度计算，从而支持未见说话人的比对和识别。

► 训练时分类，推理时取 embedding

🎓 训练时：分类（使用 speaker classification objective）

模型学习区分训练集中的说话人，每个说话人对应该一个 id。



关键点

- 训练目标：最小化 speaker classification 的交叉熵损失。
- 输出：预测训练集中某个 speaker id。

为什么用分类目标训练？

- ✓ 分类目标能提供强监督信号，帮助模型学习更判别性的表示。
- ✓ 需要大量带标签的说话人数据。




总结

训练：通过 speaker classification 学习判别性表示（embedding）。

推理：丢弃 classifier，使用 embedding 进行相似度比较，支持未见说话人。

👤 推理时：取 embedding（不使用 classifier 输出）

我们使用 classifier 前的 speaker embedding 来比较未知说话人。



为什么推理时不用 classifier？

- ✓ Classifier 只能识别训练集中出现过的 speaker。
- ✓ Embedding 捕获了说话人更本质的特征，能够迁移到未见说话人，通过相似度比较实现识别/验证。



★ 常见做法

训练后丢弃或弱化分类头，只保留 encoder 部分用于提取 embedding，再结合 cosine similarity / PLDA / 阈值等进行决策。


深度学习阶段的说话人识别模型：ECAPA-TDNN

从 TDNN / x-vector 到 ECAPA-TDNN

- x-vector 系统证明了 TDNN 可以有效提取说话人表征。
- ECAPA-TDNN 是对 TDNN speaker encoder 的增强版本。

ECAPA 可以解释为：

Emphasized **C**hannel **A**ttention, **P**ropagation and **A**ggregation in **T**DNN



ECAPA-TDNN 的关键增强点



更强的时序建模

使用 Res2Net-style 的多尺度 TDNN Block, 结合扩张卷积(dilated conv)和残差连接, 捕获更丰富的时序上下文。



通道注意力 (SE)

在每个 TDNN Block 后使用 Squeeze-and-Excitation, 自适应地强调有辨别力的通道, 抑制不重要的信息。



多层特征聚合

将多个中间层的特征进行拼接聚合, 保留不同层级的语义信息, 增强表征的多样性和鲁棒性。



注意力统计池化 (ASP)

通过学习到的时间维注意力权重, 对帧级特征进行加权统计, 比传统统计池化 (均值+标准差) 更聚焦于关键语音片段。



更好的泛化能力

综合上述机制, 获得更具区分性和鲁棒性的 speaker embedding, 在开放集和跨域场景下表现更优。


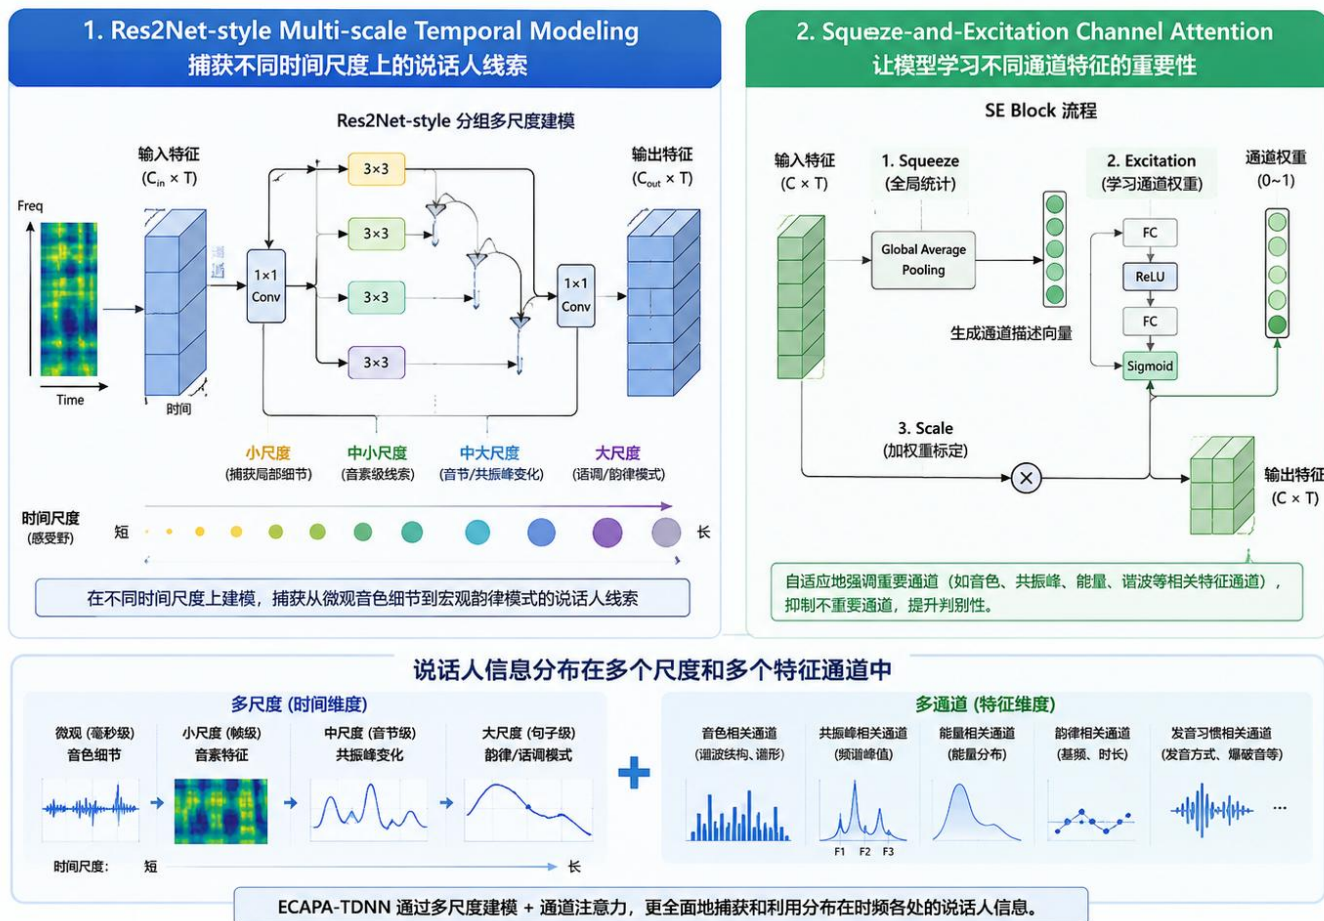



Figure 2: Network topology of the ECAPA-TDNN. We denote k for kernel size and d for dilation spacing of the Conv1D layers or SE-Res2Blocks. C and T correspond to the channel and temporal dimension of the intermediate feature-maps respectively. S is the number of training speakers.

深度学习阶段的说话人识别模型：ECAPA-TDNN

ECAPA-TDNN 的两个关键改进


说话人信息不是只存在于某一个短帧中，而是分布在音色、共振峰、韵律、发音习惯等**多个尺度**和**多个特征通道**中。



深度学习阶段的说话人识别模型：ECAPA-TDNN


为什么语音需要 pooling?

🎯 核心问题：语音长度可变，但 embedding 维度必须固定




⚠️ 普通平均池化的问题

- ❌ 每一帧对说话人信息贡献不同
- ❌ 静音、噪声、弱发音帧会被同等对待
- ❌ 重要的、有区分度的帧被稀释，判别性下降




ECAPA-TDNN: Attentive Statistics Pooling



直观解释

- ✓ 不是所有帧都同样有用
- ✓ 模型学习注意力权重 a_t
- ✓ 更关注清晰、稳定、有说话人特征的帧
- ✓ 忽略静音、噪声、弱发音帧

整体流程 (从帧到说话人 embedding)



第二部分：说话人识别实验

- 实验 1：环境安装与 ECAPA-TDNN 初次推理
- 实验 2：说话人嵌入空间与扰动分析
- 实验 3：说话人验证与说话人辨认

▶ 实验说明

实验简介

本实验基于 SpeechBrain 框架和在中文 CNCeleb 数据集上预训练的 ECAPA-TDNN 模型，围绕说话人验证与说话人辨认两类核心任务，帮助学生从模型原理和实验实现等角度理解现代深度学习说话人识别流程。

实验内容概览

包含三次实验，均为必做实验(100%)。

实验代码	实验主题
01_setup.ipynb	环境安装与 ECAPA-TDNN 初次推理
02_speaker_embedding.ipynb	说话人嵌入空间与扰动分析
03_asv_asr.ipynb	说话人验证与说话人辨认

▶ 实验说明

实验提交要求

完成 Jupyter Notebook 内的实验内容，将答案、佐证答案的图表和相关代码填写在 “姓名-学号-TTS 实验报告模板.docx” 中（也可自行改为 latex 模板，格式均不限制，美观即可）

参考资料：

ECAPA-TDNN 论文：<https://arxiv.org/abs/2005.07143>

ECAPA-TDNN 讲解：https://blog.csdn.net/m0_46324847/article/details/128613853

SpeechBrain 官方文档：<https://speechbrain.readthedocs.io/en/latest/tutorials/basics.html>



THANKS!
Q&A