

Lab6

基于AI Coding的语音识别




2026.4.30

郭昱杰 and 豆包

[与豆包的对话](#)

语音识别(Automatic Speech Recognition, ASR)

- 将语音转录成对应的文本
 - 将不定长的语音序列，映射为不定长的文本序列
 - 帧与文本之间并没有一个清晰的映射关系
- 主流架构
 - CTC, RNN-T, Transformer encoder + decoder,



Lab6-实验数据

- 数据集: [标贝数据集](#)
 - 12h数据, 一共10000条数据, 8000用来训练, 1000用来验证, 1000用来测试
 - 本次识别的目标为拼音, 风格不带声调
 - 已经为大家划分好了数据集, 并分别提供训练集, 验证集和测试集的gt
- 主要是两个文件wav.scp和pinyin
 - wav.scp: 语音id<\t>语音路径
 - pinyin: 语音<\t>目标拼音


```
wav.scp
dataset > split > dev > wav.scp
1 008001 Wave/008001.wav
2 008002 Wave/008002.wav
3 008003 Wave/008003.wav
4 008004 Wave/008004.wav
5 008005 Wave/008005.wav
6 008006 Wave/008006.wav
7 008007 Wave/008007.wav
8 008008 Wave/008008.wav
```

```
pinyin
dataset > split > dev > pinyin
1 008001 yi ge nan ren tui ran de zuo zai pang bian mu guang dai zhi
2 008002 xi huan ba li ao de shu cha zai niu zai ku de qian mian
3 008003 zha yan yi kan xiang qi de shi guang zhou de qu hao ling e er ling
4 008004 ci qian qing hua zi guang jiu ceng zao yu guo tong yang de wei ji
5 008005 bu tai ming bai shen me yi si
6 008006 hai you bu fen dan bao gong si she ji chao gu pei zi ye wu
```

数据集下载链接: <https://www.data-baker.com/data/index/TNtts/>

Lab6-实验数据

- 数据集: [标贝数据集](#)
- 请同学们下好数据后, 按照下面的目录放好
 - 如果放到其他地方, 需要去dataprocess目录下修改相应的路径, 尤其是ASRDataset类中的路径



数据集下载链接: <https://www.data-baker.com/data/index/TNtts/>

Lab6-基于AI Coding的语音识别

- 本次实验主要是实现一个以transformer encoder + CTC为框架的语音识别系统
- **问题：**我现在需要基于Transofrmer encoder + CTC的架构实现语音识别，请你大致为我梳理一下代码框架，然后我们来一步一步完成
- 豆包的回答如下（截取部分）：

四、我们的实现步骤（一步一步来）

我按**从易到难、从基础到核心**的顺序，带你逐步实现：


1. 第一步：实现**全局配置 + 音频特征提取**
2. 第二步：实现**词表 + 数据集 + 变长序列对齐**
3. 第三步：实现**Transformer Encoder + 位置编码**
4. 第四步：实现**CTC 损失 + 训练 / 验证循环**
5. 第五步：实现**CTC 解码 + 推理预测 + 评估**

思路明确：

- 预处理数据
- 实现模型
- 训练
- 推理以及评估


Lab6-预处理数据

- 主要讲解整体的框架，具体可以看与豆包的对话
- 本实验主要需要处理两个模态
 - 拼音：需要转成一个一个的token，具体可以看tokenizer.py
 - 语音：lab1已经学会如何提取
- 重点可以看一下collate_fn函数
 - 音频和拼音都是变长数据，转化为tensor的时候，每个batch中每个数据长度都要一致。collate_fn解决了长度对齐的问题。
 - 下面是豆包生成的处理流程。思路是正确的，但名字是错误的。




Lab6-模型实现与CTC

- 主要实现的是Transformer Encoder
 - Transformer的原理大家可以自行查阅，这里不过多赘述。代码部分豆包已经实现好了。
- [CTC](#)
 - 语音和拼音的长度并没有一个显示的对其关系。这里我们假设语音长度为T，拼音长度为L($T \gg L$)
 - 在模型做softmax的时候，预测出来实际上长度还是T。CTC解决了如何将长度为T的token转化成长度为L的token的问题。




Lab6-CTC原理

- CTC引入了一个blank字符，只有当预测出来blank或者新token的时候，才会转移到下一个token的预测当中。
- 如果预测的下一个token和当前token一致，则保持原来的点。
- 类似于下图，结果为[a,b]的路径有很多。只需要能从左上角到左下角就行。



Lab6-CTC原理

- 现在有了对齐方式，只需要考虑如何训练和推理
- 训练
 - 找到所有的符合结果的路径，计算概率合。之后计算loss。
 - 本质上是将模型去拟合所有的路径。
- 推理
 - 只需要对对齐的过程进行模型。具体来说，将相邻的相同token压缩成一个。之后移除掉blank，
- 如何实现上面的规则？
 - 动态规划



Lab6-评测

- 我们将WER作为评测手段。
 - WER 越低 → 识别越准确
 - WER 越高 → 识别错误越多
- 替换错误 S：正确词被识别成另一个词。例：今天 → 金天
- 删除错误 D：正确词没被识别出来。例：我去吃饭 → 我吃饭
- 插入错误 I：多识别出不存在的词。例：打开空调 → 打开空空空调

$$WER = \frac{S+D+I}{N} \times 100\%$$

- S ：替换错误数
- D ：删除错误数
- I ：插入错误数
- N ：参考文本总词数

Lab6-实验任务

- **基础任务：**基于AI Coding或者Vibe Coding完成训练代码，推理代码以及评测代码。
 - 经个人验证，豆包可以很好地完成任务，最后的WER在30%以内。
 - 助教利用豆包实现的参数配置如下图，由于模型参数量比较小且任务简单，上述是在训练10个epoch，找验证集上最优的epoch来进行测试的结果。（CPU即可，不希望大家花钱租GPU，本次实验的目的仅仅就是希望大家明白语音识别怎么做的，并且学会使用AI完成任务）。
 - 不需要去卷最后的性能。正常训练就好。如果实在训不出来，需要分析失败原因。
- **进阶任务：**和AI讨论，利用AI做出改进。改进不好也没有关系，需要分析原因。
 - 包括但不限于：替换encoder框架，使用一些预训练的encoder训CTC，等等

```
# -----  
# 模型超参数  
# -----  
'input_dim': 80,          # Fbank维度  
'd_model': 128,          # 模型维度（显存小就设256，大就设512）  
'nhead': 4,              # 注意力头数（必须能整除 d_model）  
'num_encoder_layers': 4,  # Encoder层数  
'dim_feedforward': 256,  # 前馈网络维度  
'dropout': 0.1,
```

```
# -----  
# 训练超参数  
# -----  
'batch_size': 8,          # 根据显存调整  
'epochs': 10,  
'lr': 1e-4,              # 学习率  
'grad_clip': 5.0,        # 梯度裁剪阈值  
'num_workers': 0,        # Windows设0, Linux设4
```

Lab6-实验任务

- 本实验需要提交一个实验报告，内容要求
 - 记录实验结果，并简单介绍一下你对本项目的理解
 - 如果完成进阶任务，需要描述进阶任务做了什么，为什么有效果/没效果
- 接下来是关于使用AI的一些问题（希望同学们能够交流自己的感受，而非让AI直接生成，如果有比较优秀的观点会有一定的加分）。
 - 本次实验是一个完整的 ASR 项目，而非单文件单函数的简单任务。那么你在开发过程中，主要使用的是「单模块 / 单函数逐段补全的传统 AI Coding 模式」，还是「基于全项目上下文、支持多文件联动修改的 Vibe Coding 模式」？请你结合本次使用体验，说说你的感受。
 - 在使用 AI 的过程中，AI 生成的代码一定会出现不符合预期、甚至完全错误的情况。那么你是如何定位到问题根源的？又是如何 修正代码解决问题的？
 - 你认为你和 AI 会形成怎样的长期共生关系？AI 会成为你的什么角色？你会如何构建自己的核心壁垒，避免被 AI 取代？你觉得你在了解ASR和不了解ASR的情况下，利用AI完成这个项目会有什么不同？
- 不要卷篇幅，简明扼要。

Lab6-AI使用体会

- 任务明确，描述详细
 - 让AI理解我们要做什么，现在我们有什么
 - 就像大家完成作业的时候，要有一个明确的需求
- 要具有一定的先验知识和项目经验
 - 代码条理
 - AI幻觉

Thanks

注意：如果发现在代码有问题，请及时联系助教郭昱杰。代码由豆包产生，可能有错误。